Statistiques : introduction et quelques définitions

Jean Paul Maalouf
linkedin.com/in/jean-paul-maalouf
www.statistique-formation.fr

Statistiques : Ensemble des méthodes qui ont pour objet la collecte, le traitement et l'interprétation des données (Larousse).

Qu’est-ce qu’une variable ?

Introduction et définitions

Variable

- **Variable** : élément mesurable qui peut prendre différentes valeurs.
- **Variable quantitative** : Variable qu'on peut quantifier. Elle reflète un ordre défini. L'écart entre les valeurs a une signification.
  - Quantitative **continue** : valeurs réelles. Exemples : concentration en sucre, taille, poids, prix...
  - Quantitative **discrète** : données de comptage (chiffres entiers). Exemples : la taille d'une portée de lapins, l'âge d'un enfant arrondi à l'année, nombre d'occurrences d'un évènement, le nombre de nécroses…

Variable

- **Variable qualitative** : Permet d'affecter une **catégorie** (ou **modalité**) à un individu. On ne peut pas la quantifier.
  - Qualitative **nominale** : pas de relation d'ordre entre modalités. Exemples : catégorie socioprofessionnelle, origine géographique de consommateurs, fertilisant sur une parcelle, groupe sanguin d'un patient…
  - Qualitative **ordinale** : les modalités peuvent être ordonnées. Exemples : Classes d'âge de consommateurs, état du patient (mauvais, moyen, bon, excellent)…

Comme nous le verrons par la suite, chaque type de variable (quanti ou quali) peut être exploité par des outils statistiques adaptés.

Remarque

- Dans certaines situations, les variables qualitatives ordinales sont transformées en données numériques.
- Exemple : quel est votre degré de satisfaction pour tel produit ?

Réponses possibles	Réponses transformées
Très insatisfait	1
Insatisfait	2
Moyennement satisfait	3
Satisfait	4
Très satisfait	5

- La variable transformée est traitée avec les outils propres aux variables quantitatives.

Individu, échantillon, population

- **Individu** ou **observation** : Unité statistique élémentaire (client, patient, parcelle, mesure sur une machine).
- **Population** : Tous les individus possibles.
  - La population rassemble l'ensemble des individus concernés par l'étude.
  - *Exemples* : Tous les clients potentiels pour un nouveau produit, tous les patients touchés par une maladie.
  - En général il est difficile d'étudier la population dans son ensemble.
- **Echantillon** : Un sous-ensemble représentatif de la population
  - Exemples : Echantillon de barres d'acier produites par une machine, cohorte de patients, ensemble de poissons pêchés en mer.

Individu, échantillon, population

- On utilise des **échantillons** pour tirer des **conclusions** sur la **population** d’intérêt.
- Les échantillons doivent être bien **représentatifs** de la population.

Jeu de données : clients d'une plateforme de vente de chaussures en ligne, CRM.csv

Les jeux de données sont représentés dans la majorité des cas par des individus (ou observations) en ligne et des variables en colonnes.

Variables

Individus ou observations

	A	B	C	D	E	F	G	H	I	J	K
1	**Client**	**Origine**	**Sexe**	**Taille**	**Pointure**	**Poids**	**Temps passé sur le site**	**Marque préférée**	**Montant Facture**		
2	Willard	Mars	M	9	26	50	28	Marque A	153		
3	Derrick	Pluton	M	102	40	335	39	Marque D	229		
4	Olivia	Mars	F	13	31	68	29	Marque A	118		
5	Marc	Mars	M	20	29	81	40	Marque C	160		
6	Alice	Pluton	F	116	33	378	11	Marque B	248		
7	Elijah	Mars	M	22	30	88	44	Marque C	137		
8	Clyde	Mars	M	27	29	105	42	Marque C	142		
9	Angel	Mars	F	31	28	116	51	Marque A	151		

Données inventées

Grandes familles d’outils statistiques

Introduction et définitions

Grandes familles d’outils statistiques

- Statistiques descriptives univariées
- Statistiques descriptives bivariées
- Tests statistiques
- Statistiques exploratoires multivariées
- Classification ou clustering
- Modélisation statistique
- Statistiques prédictives

Machine Learning non-supervisé

Machine Learning supervisé

Récapitulatif

Introduction et définitions

Récapitulatif : Introduction et définitions

- **Statistiques** : Ensemble des méthodes qui ont pour objet la collecte, le traitement et l'interprétation des données (Larousse).
- **Variable** : élément mesurable qui peut prendre différentes valeurs.
- **Variable quantitative** : Variable quantifiable. Peut être *continue* ou *discrète*.
- **Variable qualitative** : non-quantifiable. Représentée par des catégories (modalités). Peut être *nominale* ou *ordinale*.
- **Individu / observation** : unité statistique élémentaire.
- **Population** : ensemble des individus concernés par l’étude.
- **Echantillon** : sous-ensemble d’individus représentatifs de la population.
- Il existe **plusieurs familles** d’outils statistiques : descriptives univariées et bivariées, tests statistiques, statistiques exploratoires multivariées, clustering, modélisation, prédiction.

Statistiques descriptives univariées

Jean Paul Maalouf
linkedin.com/in/jean-paul-maalouf
www.statistique-formation.fr