Statistiques descriptives univariées

Jean Paul Maalouf
linkedin.com/in/jean-paul-maalouf
www.statistique-formation.fr

Plan – Statistiques descriptives univariées

1. Décrire une variable qualitative
2. Décrire une variable quantitative

1. Décrire une variable qualitative

Statistiques descriptives univariées

Décrire une variable qualitative

Exemple : *Marque préférée*

	B	C	D	E	F	G	H	I	J
1	**Origine**	**Sexe**	**Taille**	**Pointure**	**Poids**	**Temps passé sur le site**	**Marque préférée**	**Montant Facture**	
2	Mars	M	9	26	50	28	Marque A	153	
3	Pluton	M	102	40	335	39	Marque D	229	
4	Mars	F	13	31	68	29	Marque A	118	
5	Mars	M	20	29	81	40	Marque C	160	
6	Pluton	F	116	33	378	11	Marque B	248	
7	Mars	M	22	30	88	44	Marque C	137	
8	Mars	M	27	29	105	42	Marque C	142	
9	Mars	F	31	28	116	51	Marque A	151	
10	Terre	M	4	29	36	18	Marque A	174	
11	Terre	M	5	33	40	40	Marque C	123	
12	Pluton	M	107	32	340	15	Marque C	257	

Décrire une variable qualitative

- **Tri à plat** : nombre d’observations par modalité. Peut aussi s’exprimer en proportions.
- **Mode** : modalité la plus fréquente.
- **Diagramme en bâtons** : représentation graphique du tri à plat.
- **Diagramme en secteurs** : représentation graphique du tri à plat.

Décrire une variable qualitative

Modalité la plus fréquente

Tri à plat

Statistiques descriptives (Données qualitatives) :

Variable\Statistique	Nb. d'observations	Nb. de modalités	Mode	Mode (effectif)	Modalités	Effectif par modalité	Fréquence par modalité (%)
Marque préférée	30	4	Marque C	12	Marque A	10.000	33.333
					Marque B	4.000	13.333
					Marque C	12.000	40.000
					Marque D	4.000	13.333

Décrire une variable qualitative : representations graphiques du tri à plat

Diagramme en bâtons

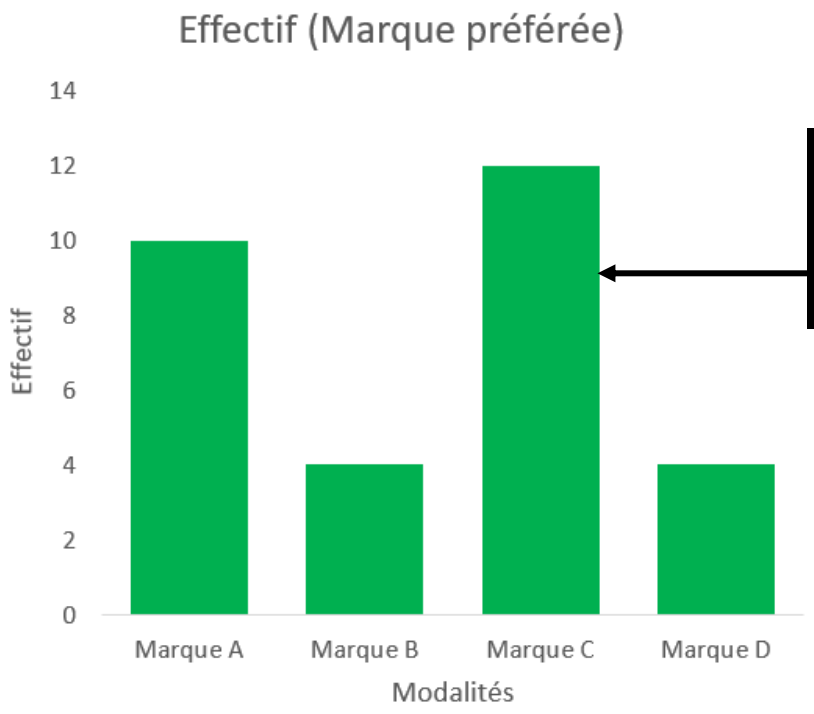

On retrouve le mode

Diagramme en secteurs

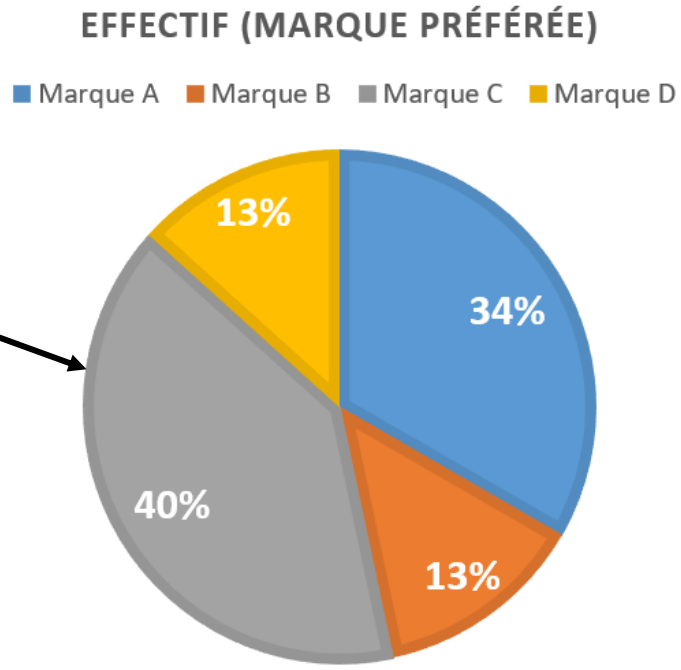

Récapitulatif

Décrire une variable qualitative

Récapitulatif : décrire une variable qualitative

- **Tri à plat** : dénombrement des **effectifs** de chaque modalité. Peut également s’exprimer en proportions ou pourcentages.
- **Mode** : modalité la plus fréquente.
- **Diagramme en bâtons** : représentation graphique du tri à plat.
- **Diagramme en secteurs** : représentation graphique du tri à plat.

2. Décrire une variable quantitative

Statistiques descriptives univariées

Décrire une variable quantitative

Exemple : *Pointure*

	B	C	D	E	F	G	H	I	J
1	**Origine**	**Sexe**	**Taille**	**Pointure**	**Poids**	**Temps passé sur le site**	**Marque préférée**	**Montant Facture**	
2	Mars	M	9	26	50	28	Marque A	153	
3	Pluton	M	102	40	335	39	Marque D	229	
4	Mars	F	13	31	68	29	Marque A	118	
5	Mars	M	20	29	81	40	Marque C	160	
6	Pluton	F	116	33	378	11	Marque B	248	
7	Mars	M	22	30	88	44	Marque C	137	
8	Mars	M	27	29	105	42	Marque C	142	
9	Mars	F	31	28	116	51	Marque A	151	
10	Terre	M	4	29	36	18	Marque A	174	
11	Terre	M	5	33	40	40	Marque C	123	
12	Pluton	M	107	32	340	15	Marque C	257	

Décrire une variable quantitative

- **Tendance centrale** : moyenne, médiane.
- **Dispersion** : écart type, coefficient de variation, variance...
- **Box plot** : représentation graphique de la tendance centrale et de la dispersion ; détection de données extrêmes.
- **Histogramme** : représentation graphique de la *distribution* des valeurs.
- ...

La Tendance Centrale

Décrire une variable quantitative

Décrire une variable quantitative : tendance centrale

- **Tendance centrale** : décrire le **centre** des données
- **Moyenne** : $\bar{x} = \frac{1}{n} \sum_i x_i$
- **Médiane** : donnée qui divise en 2 parties l'échantillon tel que chaque partie contient le même nombre de valeurs.

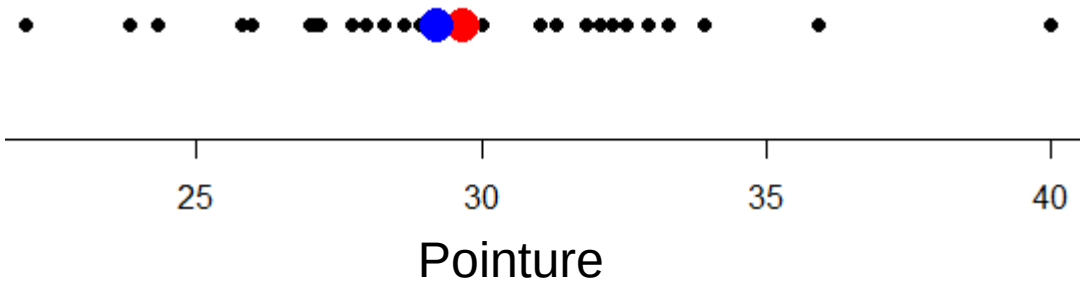

Moyenne
Médiane (donnée du milieu)

Décrire une variable quantitative : tendance centrale

- Préférer la médiane lorsque la distribution n'est pas symétrique ou que vous souhaitez minimiser l'influence de valeurs extrêmes.

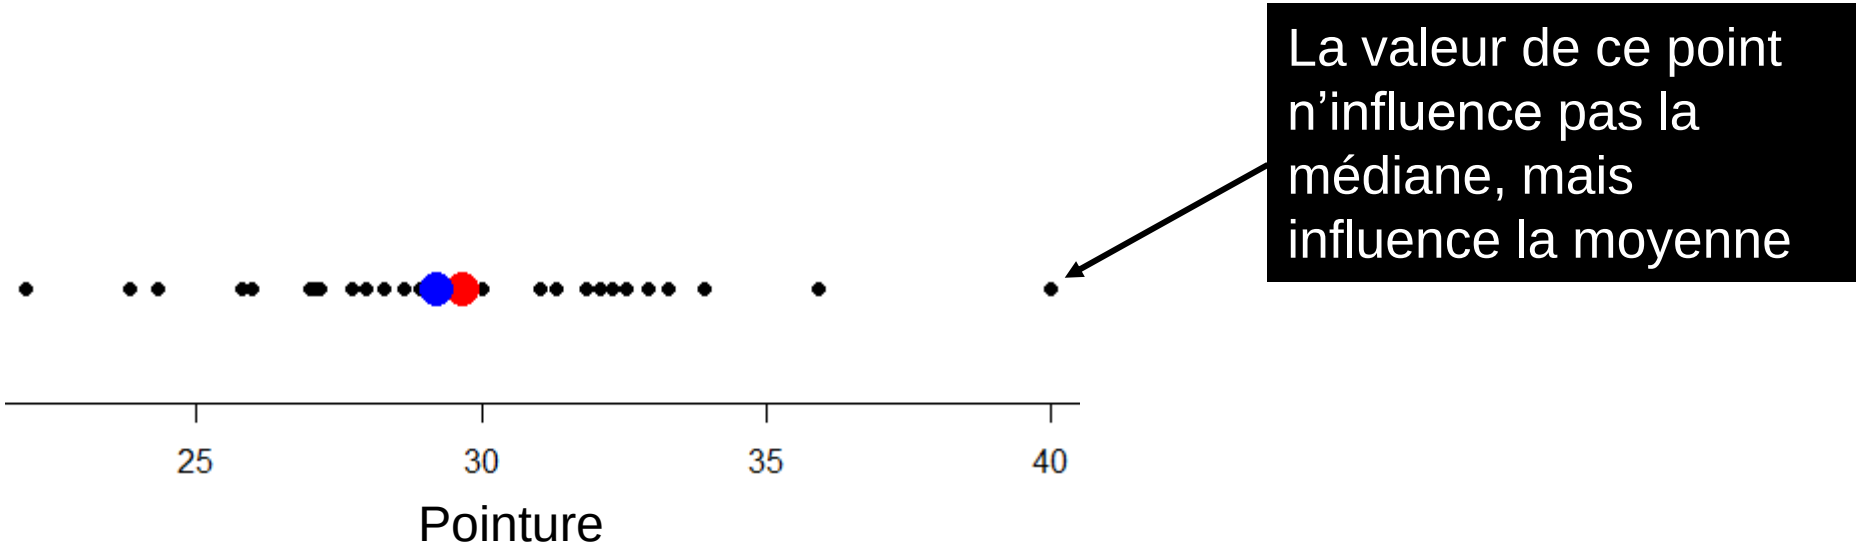

La dispersion

Décrire une variable quantitative

Décrire une variable quantitative : dispersion

- La dispersion reflète l'**importance des écarts** des points par rapport à la tendance centrale.
- Elle peut être mesurée par l'**écart type**.
- La formule suivante calcule l'**écart type d'une population** :

$$\sigma = \sqrt{\frac{\sum(x_i - \mu)^2}{N}}$$

  - μ : moyenne de la population
  - N : taille de la population
  - x_i : chaque valeur de la population

Décrire une variable quantitative : dispersion

- Remarque : nous avons **rarement accès** à toutes les données de la **population**.
- Il est possible d'**estimer l'écart type de la population** grâce aux données de l'**échantillon**. Formule :

$$s = \sqrt{\frac{\sum(x_i - \bar{x})^2}{n-1}}$$

  - $\bar{x}$: moyenne de l'échantillon (estimation de la moyenne de la population).
  - n : taille de l'échantillon.
  - x_i : chaque valeur de l'échantillon.
- Dans la pratique, cette deuxième formule est à **privilégier la plupart du temps** (à moins d'avoir accès à l'intégralité de la population).

Décrire une variable quantitative : interpréter l'écart type

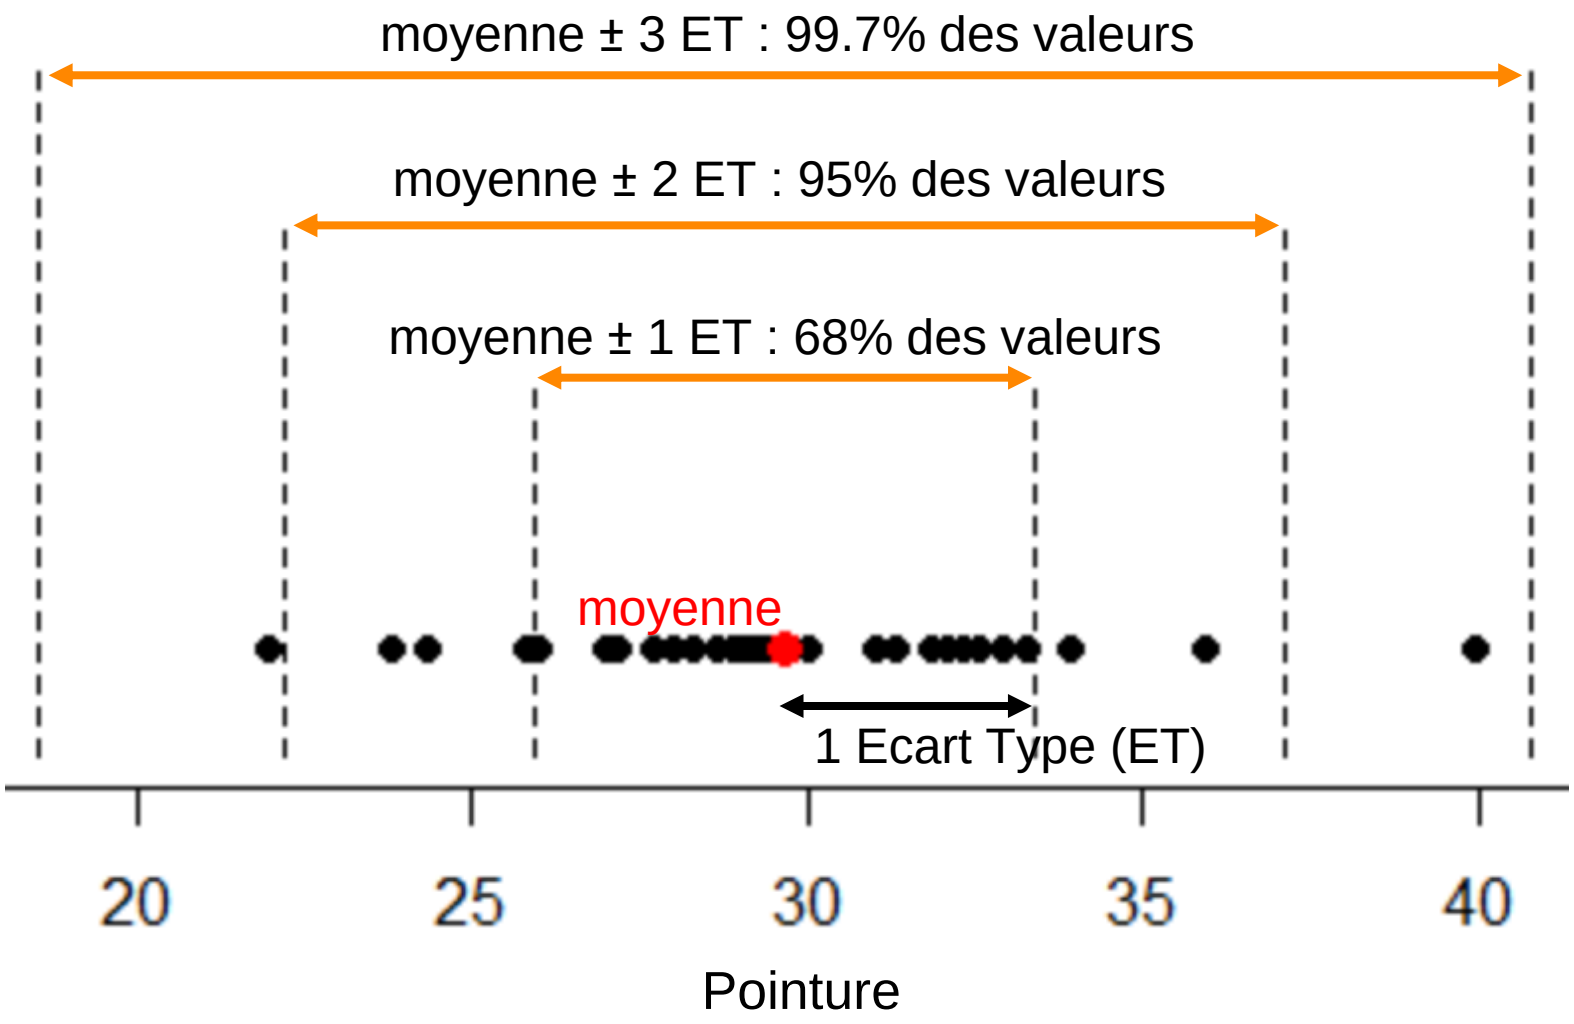

Décrire une variable quantitative : dispersion

- Autres descripteurs de la dispersion des données :
- La **variance** = écart type².
  - **Non-recomandée** pour **l'aspect descriptif**, parce qu'elle n'est pas mesurée sur la même échelle que les données.
  - Utile dans certains calculs statistiques (ANOVA...).
- Le **coefficient de variation** = écart type/moyenne.
  - Utile pour comparer les **dispersions de variables** mesurées à **des échelles différentes**.
  - Exemple : le poids est-il plus ou moins dispersé que l'âge ?
- Comme l'écart type, variance et coefficient de variation ont :
  - Leur formule pour les **données** de toute la **population** (**formule n**)
  - Leur formule pour l'**estimation** à partir d'un **échantillon** (**formule n-1**)

Décrire une variable quantitative : dispersion

- Autres descripteurs de la dispersion des données :
- Les **quartiles** (Q1, Q2 et Q3) : divisent l'échantillon en 4 parties comprenant un nombre égal de données.

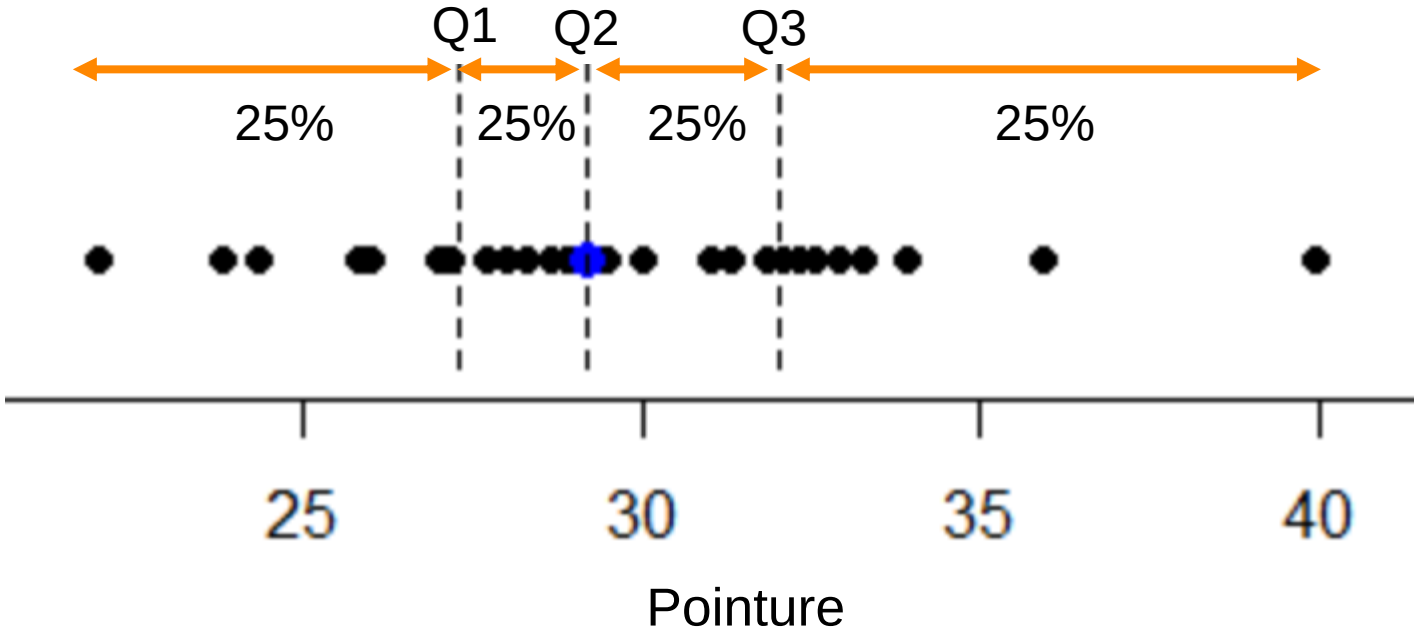

- PS : Q2 n'est autre que la médiane.

Décrire une variable quantitative : dispersion

- L’**écart Interquartile** (IQR) = Q3 – Q1 est un indicateur robuste de la dispersion des données.

- Il est possible de **diviser** l’échantillon en parties égales encore plus petites (dix **déciles**, cent **centiles**...).

Décrire une variable quantitative

Statistique	Pointure
Nb. d'observations	30
Minimum	21.990
Maximum	39.990
1er Quartile	27.308
Médiane	29.215
3ème Quartile	32.028
Moyenne	29.663
Variance (n-1)	13.842
Ecart-type (n-1)	3.721
Coefficient de variation (n-1)	0.125

25% des données se trouvent en-dessous de cette valeur

Tendance centrale

25% des données se trouvent au-dessus de cette valeur

Tendance centrale

95% des valeurs dans la population se trouvent entre (29.7 – 2*3.7) et (29.7 + 2*3.7)

Dispersion : 12.5%. Peut être comparée avec la dispersion d'autres variables. Exemple : taille

Box Plot

Décrire une variable quantitative

Décrire une variable quantitative : Box Plot

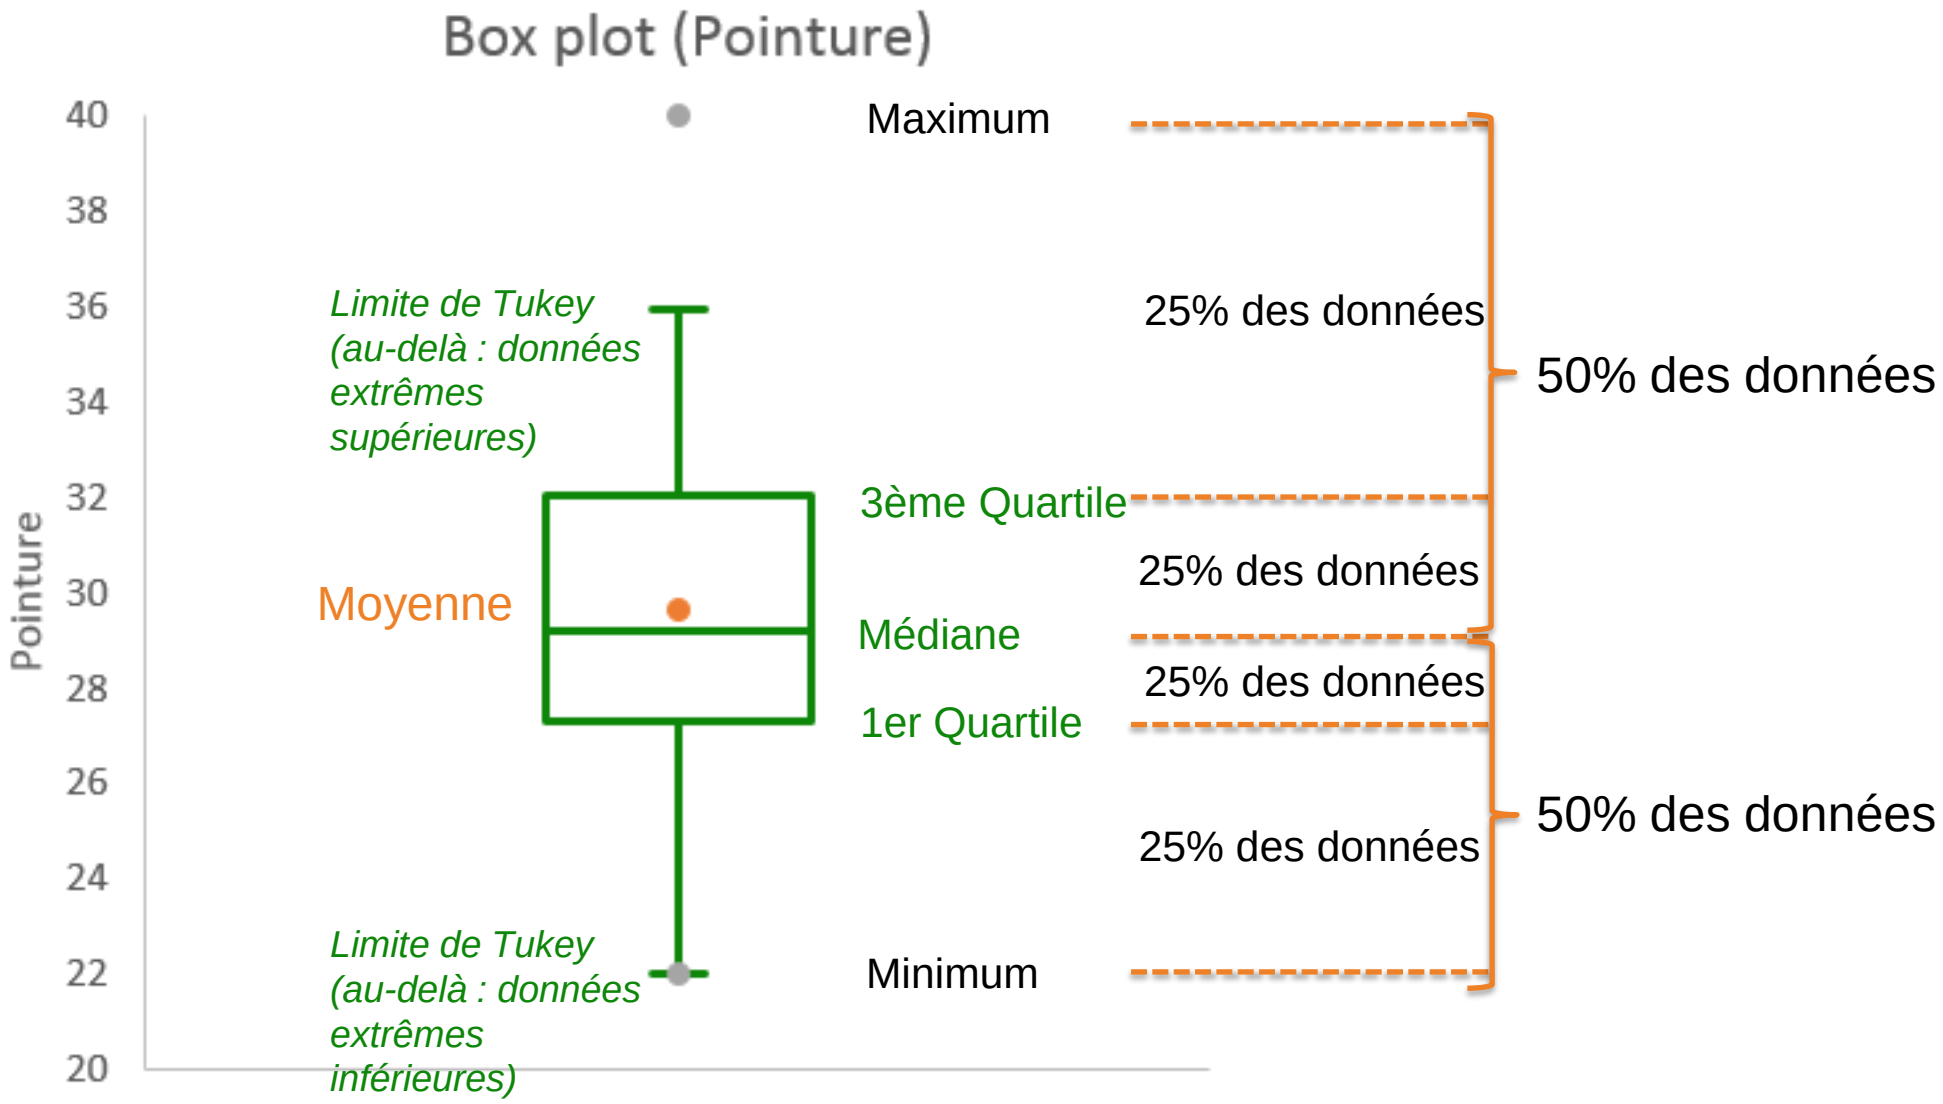

Lien
Tutoriel
Box plots

Distribution et histogramme

Décrire une variable quantitative

Décrire une variable quantitative : distribution et histogramme

- La **distribution statistique** représente la densité d'observations sur les différentes valeurs possibles d'une variable.
- Visualisation d'une distribution : **histogramme**.
- Les 2 diapos suivantes montrent les étapes de la construction d'un **histogramme sur des données observées** (on parle de distribution **empirique**).

Décrire une variable quantitative : distribution et histogramme

- Etape 1 : on divise l'étendue des données en intervalles réguliers.

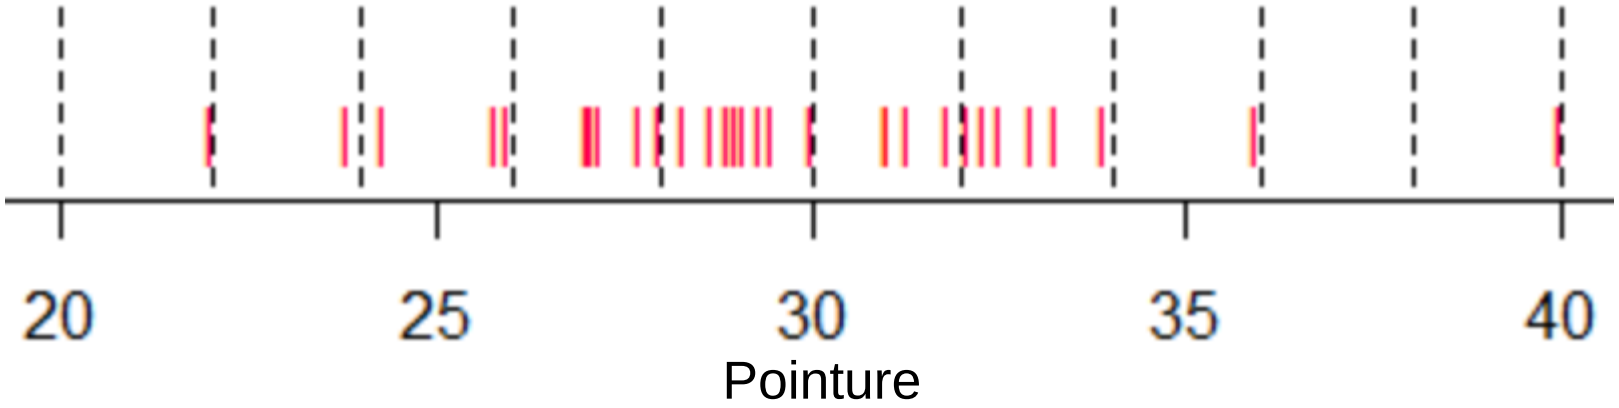

Décrire une variable quantitative : distribution et histogramme

- Etape 2 : on comptabilise le nombre de points dans chaque intervalle

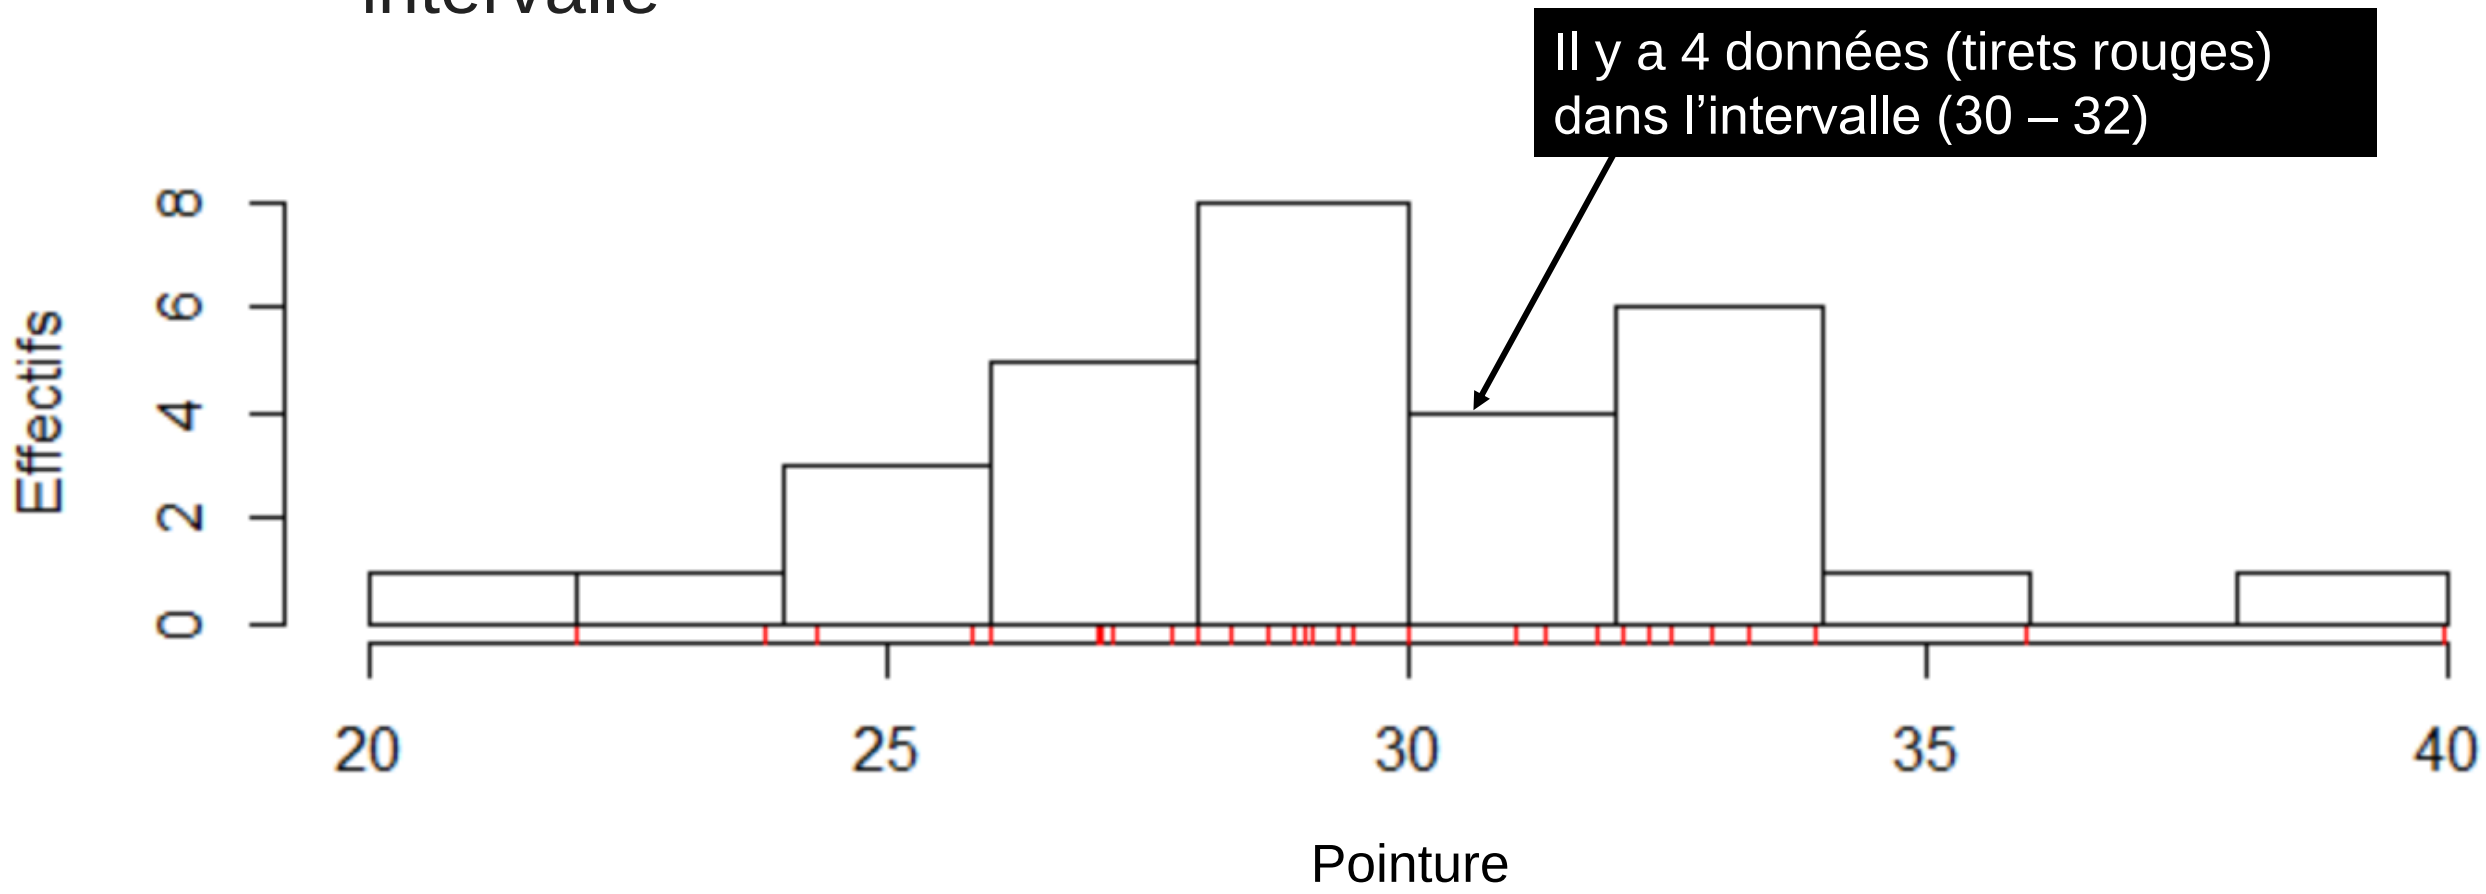

Décrire une variable quantitative : histogramme

- La densité d'observations est plus **importante autour de la moyenne**.
- La densité diminue progressivement en s'éloignant de la moyenne.
- Cette distribution **symétrique en cloche** est aussi appelée distribution **gaussienne** ou **normale**.
- La distribution normale a des propriétés statistiques intéressantes.

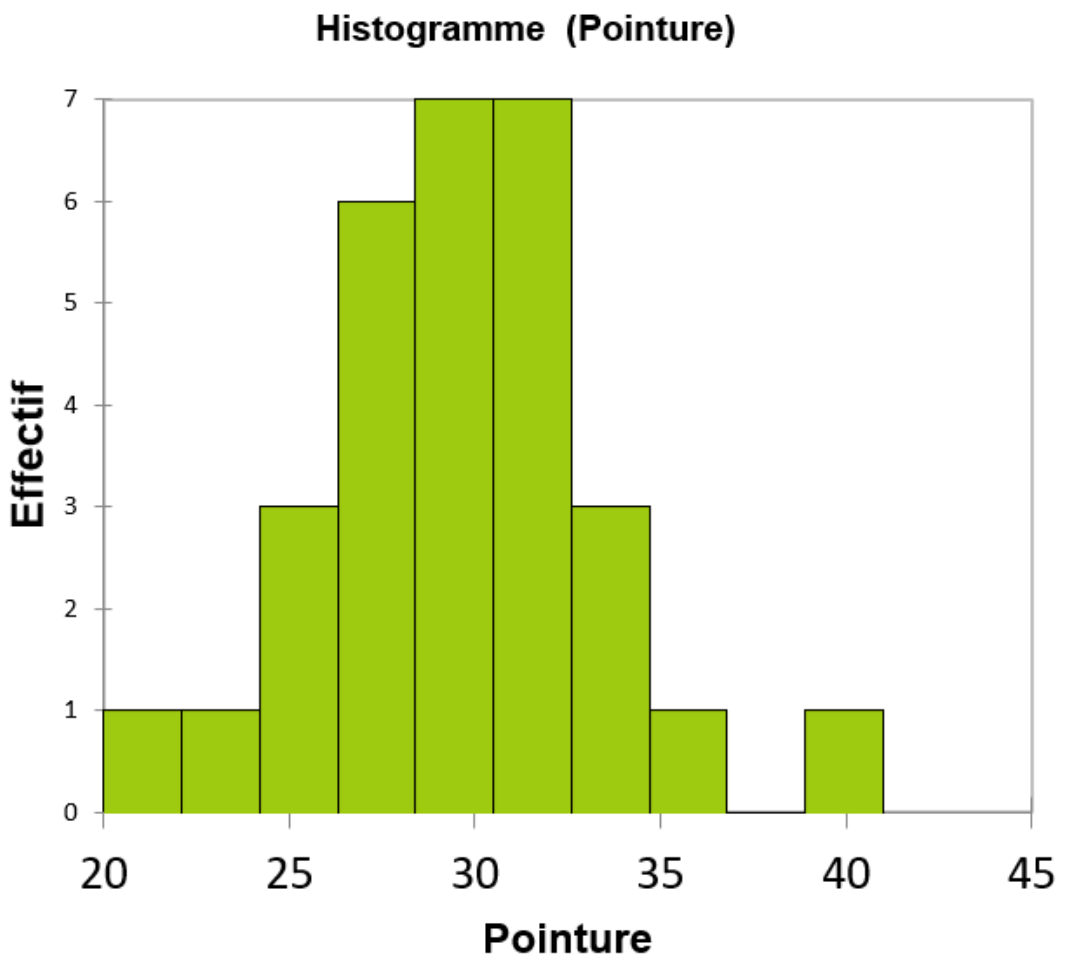

Récapitulatif

Décrire une variable quantitative

Récapitulatif : décrire une variable quantitative

- **Tendance centrale :**
  - **Moyenne** : somme des valeurs divisée par l'effectif.
  - **Médiane** : trier les données par ordre croissant ; la médiane est la donnée du milieu.
  - **Préférer** la médiane pour limiter l'influence des données extrêmes.
- **Dispersion** :
  - **Ecart-type** : 95% des données se trouvent dans l'intervalle moyenne ± 2 écarts types.
  - **Coefficient de variation** : écart-type standardisé.
  - **Variance** : Ecart-type².
  - **Quartiles** : divisent la série de données en 4 tranches à effectifs égaux.
- **Représentations graphiques** :
  - **Box pot** : représente la médiane, quartiles et limites de Tukey (données extrêmes)
  - **Histogramme** : représente la distribution des données (normale si en forme "de cloche")

Bonus : Intervalles de confiance

Statistiques descriptives univariées

Mesurer la confiance qu’on peut avoir dans l’estimation de la moyenne

Décrire une variable quantitative

Mesurer la confiance qu’on peut avoir dans l’estimation de la moyenne

- Nous avons **estimé** la **moyenne** de la pointure d’une population de clients à partir d’un échantillon.
- Comment **mesurer la confiance** qu’on peut avoir autour de cette estimation ?

Mesurer la confiance qu'on peut avoir dans l'estimation de la moyenne

- Imaginons un scénario :
  - On tire 1000 échantillons dans la population avec 30 individus à chaque fois.
  - On calcule la **moyenne** de chaque échantillon.

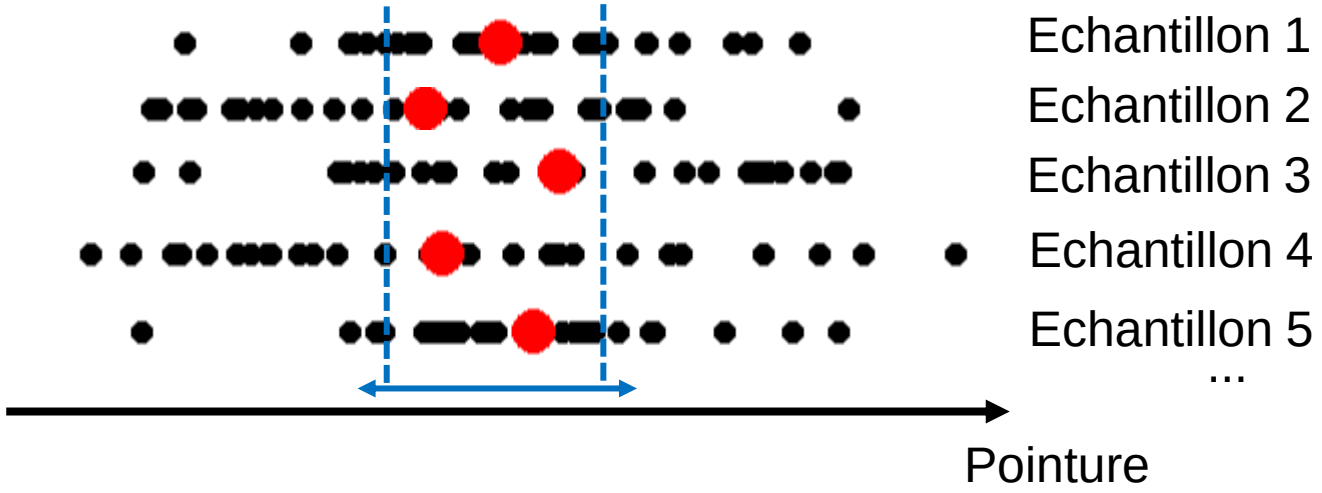

  - La **dispersion** des moyennes des échantillons reflète la fiabilité de l'estimation de la moyenne sur chaque échantillon à part.
  - Plus la **dispersion** de ces moyennes est importante, moins on pourra attribuer de la confiance à l'estimation de notre moyenne.

Mesurer la confiance qu'on peut avoir dans l'estimation de la moyenne

- La dispersion des moyennes des échantillons est appelée **écart type de la moyenne** ou **erreur standard**.
- Elle mesure le *manque de fiabilité* de l'estimation de la moyenne de la population à partir d'un échantillon.
- L'écart type de la moyenne peut être **calculé analytiquement** = $\frac{s}{\sqrt{n}}$ = 0.679 pour notre estimation de la moyenne de pointures.
- Rappel de la valeur de notre moyenne estimée : 29.7.
- Calcul d'un **intervalle de confiance (IC) à 95%** : 95% des valeurs de moyennes d'échantillons théoriques se trouveront *grossièrement* entre (29.7 – 2 x 0.679) et (29.7 + 2 x 0.679).
- Interprétation plus *intelligible* de l'IC, mais moins *correcte* ☺ : il est probable à 95% que la moyenne de la population se trouve entre les deux bornes de l'intervalle.

Intervalle de Confiance

- La notion d'Intervalle de Confiance peut s'appliquer sur des paramètres autres que la moyenne.
- *Exemple courant* : Intervalle de Confiance autour de l'estimation d'un **Pourcentage**.
- A partir d'un échantillon, on pourra dire que le pourcentage de consommateurs qui préfèrent le produit A par rapport au produit B aura une probabilité de 95% de se retrouver entre 31% et 37% dans la population.
- **Ce deuxième exemple correspond encore une fois à une interprétation plus *intelligible* de l'IC, mais moins *correcte***
- Interprétations correctes d'un IC à 95% :
  - Exemple de la moyenne : Si on répétait l'échantillonnage dans les mêmes conditions infinité de fois, la moyenne de la population se trouvera entre les deux bornes de l'IC 95 fois sur 100.
  - Exemple du pourcentage : Si on répétait l'échantillonnage dans les mêmes conditions infinité de fois, le pourcentage réel de la population se trouvera entre les deux bornes de l'IC 95 fois sur 100.

Récapitulatif

Décrire une variable quantitative

Récapitulatif : Intervalle de Confiance

- **Mesurer la confiance autour de l'estimation de la moyenne** :
  - **Erreur Standard** (ou écart-type de la moyenne) : plus elle est élevée, plus l'estimation est *vague*.
  - **Intervalle de Confiance à 95%** : plus il est étroit, plus l'estimation est fiable.

C’est le moment de mettre tout ça en pratique !

Fin !

Des questions ?

Vous pouvez me contacter sur
www.statistique-formation.fr